DECISÃO EXECUTIVA

Trazer capacidade de IA para dentro da engenharia

> **Siglas e notações: IA**: inteligência artificial; **UI**: interface do usuário.

Um piloto de **seis semanas** para reduzir despesa variável, conservar contexto sensível e manter alternativas.

Local primeiro.
Nuvem quando agregar valor.

Escopo: código, backend, UI e testes. Híbrido significa local + nuvem.

Proposta de planejamento · 16 outubro 2026

01 / O PROBLEMA

O consumo por token muda a conta

Siglas e notações: US$: dólares dos Estados Unidos.

O relato do time aponta usuários com gastos de **US$ 2 mil–10 mil**. Assumimos aqui valores mensais por profissional; validar nas faturas.

US$ 10 mil

5 pessoas × US$ 2 mil/mês

US$ 50 mil

5 pessoas × US$ 10 mil/mês

Não é média de mercado. Cache, contexto repetido e agentes paralelos precisam aparecer na linha de base.

Relato fornecido pelo usuário · cenários aritméticos; nenhuma fatura auditada

02 / OPORTUNIDADE

Modelos compactos merecem qualificação

Siglas e notações: SWE: engenharia de software; família de benchmarks de tarefas de software; **B / A…B**: B indica bilhões de parâmetros; A antes da contagem indica parâmetros ativos por token.

Benchmark	Qwen3.6 · 27B	Qwen3.8 · 27B
Terminal Bench 2.1	63,4	**73,0**
SWE-bench Pro	53,5	**61,7**
NL2Repo	36,2	**42,3**

Mesmo número nominal de parâmetros, maior resultado publicado. Validar quantização e tarefas internas; dataset não foi isolado como causa única.

Qwen · avaliação dos próprios autores

Economia híbrida depende da tarefa

Siglas e notações: US$: dólares dos Estados Unidos.

Tarefa	Nuvem → híbrido	Variação
Mapper Ktor	US$ 0,339 → 0,134	−60,5%
Renomeação TypeScript	US$ 0,227 → 0,121	−46,7%
Campo Spring	US$ 0,092 → 0,164	+78,3%

Qwen local no Mac + Sonnet remoto. Selecionar famílias pelo custo por tarefa aceita; não são economias mensais de time.

Começar também com 32, 48 e 64 GB

Siglas e notações: GB: gigabyte, unidade decimal de capacidade de dados; **MoE**: mistura de especialistas; ativa parte das redes de especialistas por token; **MLX**: framework de aprendizado de máquina da Apple; nome de runtime, não de quantização; **oMLX**: software de serviço de modelos construído sobre MLX; **MTP**: predição de múltiplos tokens para geração especulativa; **Q4**: família de quantização em 4 bits; sufixos identificam o formato específico; **Q8**: família de quantização em 8 bits; sufixos identificam o formato específico; **tok/s**: tokens por segundo; medida de vazão; **B / A…B**: B indica bilhões de parâmetros; A antes da contagem indica parâmetros ativos por token.

Mac	Modelo / runtime	Decode tok/s
M1 Pro · 32 GB	35B MoE Q4 · llama.cpp	25,4
M4 Pro · 48 GB	27B Q4 · Rapid-MLX	15,2
M4 Pro · 64 GB	27B Q4 / Q8 · oMLX + MTP	20,8 / 16,6

Reutilizar estações antes de comprar. Protocolos distintos; o teste de 32 GB registra swap no host. Memória não determina sozinha velocidade ou qualidade.

M1 Pro 32 GB · M4 Pro 48 GB · M4 Pro 64 GB

05 / ARQUITETURA

Conservar contexto. Escalonar por política.

Siglas e notações: UI: interface do usuário; **IDE**: ambiente integrado de desenvolvimento.

Repositório + IDE

Identidade e escopo por projeto

→

Modelo local + ferramentas isoladas

Busca, edição, testes e logs controlados

→

Validação automática + revisão

Build, testes, contratos e UI

Exceções autorizadas: gateway minimiza contexto e chama a nuvem. Dados proibidos de sair permanecem locais.

Arquitetura proposta · fallback nunca substitui autorização de dados

06 / SEGURANÇA

Internet com limites verificáveis

Executor isolado do agente → modelo local autenticado → testes descartáveis.

Documentação por intermediário restrito. Exportação para nuvem por autorização separada.

Sem credenciais de produção, mounts amplos do host ou saída irrestrita pelo shell. Revisar workflows e hooks gerados, além do código.

Modelo de segurança Docker · Runtime de sandbox

Qualificar OMP, OpenCode e Aider

Siglas e notações: MLX: framework de aprendizado de máquina da Apple; nome de runtime, não de quantização; **OMP**: Oh My Pi; agente de programação; **VM**: máquina virtual; **SO**: sistema operacional.

Camada	Decisão
MLX / llama.cpp	Gateway privado de inferência autenticada
Agente	Política efetiva restrita de ferramentas
Execução	Limite de SO/VM e rede controlada
Aceitação	Testes independentes e revisão humana

Implantação open weight é gerenciável. O nome do agente não garante segurança.

OpenCode · OMP · Aider

07 / VALIDAÇÃO DE SEGURANÇA

Demonstrar contenção antes de ampliar

Testar instruções maliciosas no repositório, redirecionamentos web, exportação de segredo sintético, scripts de dependências e acesso fora do worktree.

Verificar que configurações de projeto não relaxam políticas corporativas e que fallback não ignora restrições de dados.

Evidência: operações negadas, tráfego, patches aceitos e execução limitada. Canais físicos ficam no apêndice especializado.

Camadas de isolamento e limitações documentadas

Usar nuvem para melhorar fluxos locais reutilizáveis

Otimizador de nuvem propõe harness por tarefa. Testes independentes selecionam a versão. O modelo local executa o trabalho recorrente.

Versionar instruções, recuperação, ferramentas e reparo limitado; manter rollback e testes de aceitação intocados.

SkillOpt apoia otimizar skills sem alterar pesos. Economia de código ainda exige medição no repositório real.

Microsoft SkillOpt

09 / O QUE MUDA NO TRABALHO

Começar por tarefas verificáveis

Siglas e notações: QA: garantia da qualidade; **UI**: interface do usuário; **API**: interface de programação de aplicações; conecta componentes de software; **E2E**: testes de ponta a ponta que cobrem o fluxo completo; **SQL**: Structured Query Language; linguagem de consulta a bancos de dados.

Frente	Aplicação inicial	Gate
Backend	APIs, SQL e refatoração delimitada	Contratos + testes
QA	Casos, fixtures e regressões	Execução + cobertura útil
UI	Componentes e correções visuais	Capturas + acessibilidade + E2E
Legado	Explicação e mudanças por módulo	Caracterização de comportamento

Aceitar código exige evidência de execução, mesmo quando o agente declara que terminou.

Plano proposto para engenharia; taxas internas serão medidas no piloto

10 / INVESTIMENTO

US$ 41.400 para qualificar o caminho

Siglas e notações: US$: dólares dos Estados Unidos.

Componente	Premissa	US$
Estações	5 × 5.000	25.000
Integração	80 h × 100	8.000
Segurança + validação	30 h × 100	3.000
Contingência	15%	5.400

Operação adicional estimada: **US$ 500/mês**. Configurações e preços ainda precisam de cotação.

Cenário de planejamento, não proposta comercial de fornecedor

A parcela evitada decide o payback

Siglas e notações: API: interface de programação de aplicações; conecta componentes de software; **US$**: dólares dos Estados Unidos.

API / pessoa / mês	Economia do time / mês	Retorno
US$ 2.000	US$ 4.500	9,20 meses
US$ 5.000	US$ 12.000	3,45 meses
US$ 10.000	US$ 24.500	1,69 mês

5 usuários · 50% de fatura evitada · US$ 500/mês de operação · investimento completo de US$ 41.400.

Sensibilidade: no primeiro cenário, evitar só 20% leva o retorno a 27,6 meses.

Cálculo próprio · retrabalho adicional deve ser descontado · calculadora na proposta

Seis semanas, critérios definidos antes

Siglas e notações: pp: pontos percentuais ao comparar porcentagens; pp minúsculo em comandos de benchmark indica processamento do prompt.

1

Linha de base

Faturas, tarefas, qualidade e revisão

2

Implantação

Configuração, isolamento e controles

3–5

Comparação

Tarefas reais, fluxo atual versus híbrido

6

Decisão

Economia, qualidade, segurança e capacidade

Metas propostas: ≥30% de economia total; ≤5 pp de perda de aceitação; ≤10% de aumento no ciclo; nenhuma exposição nos testes definidos.

Critérios para negociação; não são resultados já alcançados

Comprar evidência antes de escalar

Siglas e notações: **QA**: garantia da qualidade; **FinOps**: prática de operações financeiras para gerir consumo e custo de tecnologia.

Aprovar o piloto, confirmar a linha de base e tornar a expansão dependente de resultado.

Custo por tarefa aceita.
Dados sob política.
Versões sob controle.

Plataforma + Segurança + FinOps + Engenharia/QA compartilham a decisão.

Próximo passo proposto · sem compra, contratação ou publicação automática

Da decisão ao detalhe

> **Siglas e notações: SSD**: unidade de armazenamento de estado sólido; **GB**: gigabyte, unidade decimal de capacidade de dados; **MLX**: framework de aprendizado de máquina da Apple; nome de runtime, não de quantização; **PDF**: formato portátil de documento.

Pesquisa completa

Casos empresariais, tabelas de Macs 16–512 GB, MLX/llama.cpp, SSD, especialistas e segurança.

Abrir relatório →

Proposta de investimento

Problem/Context, Solution, Required Investment e calculadora de sensibilidade.

Abrir proposta →

As fontes estão nos rodapés e nos documentos. Setas navegam entre slides; “Imprimir / PDF” exporta a apresentação inteira.

Pacote offline · 16 outubro 2026

APOIO TÉCNICO / SSD

Modelos maiores nas mesmas estações

Siglas e notações: CPU: unidade central de processamento; **SSD**: unidade de armazenamento de estado sólido; **GB**: gigabyte, unidade decimal de capacidade de dados; **IQ2_K**: formato de quantização de poucos bits usado para pesos do modelo; **WARP**: Weight-Aware Runtime and Paging; runtime de inferência com streaming de pesos; **tok/s**: tokens por segundo; medida de vazão.

Mac / modelo	Caminho SSD	Decode tok/s
32 GB M1 Max · Flash-Next	MoEspresso · IQ2_K predominante	12–15
48 GB M5 Pro · Flash-Next	Slotstream · 4-bit	~12
64 GB M5 Pro · Flash-Next	Fork llama.cpp / Slipstream	27,6 / 35,0–37,5
64 GB M5 Pro · DeepSeek V4.1	WARP · CPU	3,77 / 3,71

Resultados dos autores, sem protocolo comum. MoEspresso altera roteamento. WARP mede 64 / 200 tokens; não comprova a meta de 20–30.

MoEspresso · Slotstream · 64 GB · WARP · Slipstream

APOIO À DECISÃO / INVESTIMENTO

Menor compra, mesma disciplina econômica

> **Siglas e notações: GPU**: unidade de processamento gráfico; **RAM**: memória de acesso aleatório; memória de trabalho; **VRAM**: memória de vídeo disponível ao processador gráfico; **SSD**: unidade de armazenamento de estado sólido; **GB**: gigabyte, unidade decimal de capacidade de dados; **US$**: dólares dos Estados Unidos.

Comparar reaproveitamento com estações de **US$ 2500–5000**: cinco unidades somam US$ 12500–25000 em hardware. Valores de planejamento; cotar configuração e SSD.

O relato doméstico de ~60 tokens/s usa GPU de 32 GB VRAM + 64 GB RAM + SSD; ainda sem logs e configuração completa. Não é benchmark de Mac.

Medir quatro caminhos: nuvem, local genérico, local com harness e local com harness + nuvem. Aprovar pela economia líquida, qualidade, tempo e contenção de dados.

Proposta de piloto · relato sem reprodução independente · TCO inclui integração e operação